

Agrupamento de Notícias com Análise por LLM

Representações Frequentiais e Semânticas · 4 Algoritmos · Explicação Automática

Cauã Vitor

Orientador: Prof. José Alfredo F. Costa

Universidade Federal do Rio Grande do Norte
Departamento de Engenharia de Computação e Automação (DCA)

Junho de 2026

Roteiro da Apresentação

- 1 Motivação e Objetivo
- 2 Representações Vetoriais
- 3 Algoritmos de Clustering
- 4 Métricas de Avaliação
- 5 Resultados Experimentais
- 6 Explicação Semântica via LLM
- 7 Visualizador Interativo

- **Problema:** Agrupar notícias em categorias temáticas *sem supervisão humana* — tarefa clássica e desafiadora em PLN.
- **Dataset:** 315 notícias em português, **6 classes**:
 - Economia, Esportes, Política
 - Polícia e Direitos, Turismo
 - Variedades e Sociedade
- **Questão de Pesquisa:** Qual representação vetorial e qual algoritmo produz grupos mais coerentes com a semântica humana?

Pipeline do Experimento

- 1 Vetorização: TF-IDF vs Embeddings
- 2 Clustering: 4 algoritmos × 3 representações
- 3 Projeção 2D: PCA, t-SNE, UMAP
- 4 Seleção de landmarks (medoides/fronteiras)
- 5 Explicação semântica via LLM

TF-IDF (Frequencial)

- Clássico *bag-of-words*: ignora contexto semântico
- Vocabulário: até **1.000 termos** após remoção de *stopwords* em PT
- Vetores esparsos de alta dimensão

$$\text{TF-IDF}(t, d, D) = \text{tf}(t, d) \cdot \log\left(\frac{|D|}{1 + |\{d: t \in d\}|}\right)$$

Embeddings Semânticos Densos

- Redes neurais que capturam sinônimos, contexto e relações implícitas
- **Sentence Transformers:**
paraphrase-multilingual-MiniLM-L12-v2
384 dim — **treinado em PT-BR**
- **Ollama (local):**
nomic-embed-text — 768 dim

Algoritmos de Agrupamento Testados

K-Means

Particional. Minimiza inércia intra-cluster. Assume grupos convexos de tamanho similar ($K = 6$).

DBSCAN

Baseado em densidade. Classifica pontos isolados como ruído (-1). Sensível ao parâmetro ε e à dimensionalidade.

Agglomerative (Ward)

Hierárquico ascendente (*bottom-up*). Mescla pares pelo critério de Ward: menor variância intra-grupo.

HDBSCAN

Extensão hierárquica do DBSCAN. Suporta densidades variáveis sem ε fixo. Mais robusto a *outliers*.

Não Supervisionadas

- **Coeficiente de Silhueta** $s(i) \in [-1, +1]$:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

$a(i)$: distância média intra-cluster; $b(i)$: distância média ao cluster vizinho mais próximo.

- **Davies-Bouldin** $\downarrow$: clusters mais compactos e separados.

Supervisionadas (vs. Ground Truth)

- **ARI** (Adjusted Rand Index): concordância corrigida pelo acaso. Ideal = 1,0.
- **NMI** (Normalized Mutual Info): alinhamento via teoria da informação. Varia em $[0, 1]$.
- **Pureza**: fração das amostras na classe majoritária de cada cluster.

Resultados Quantitativos — 12 Configurações


Representação	Algoritmo	Silhueta	ARI ↑	NMI ↑	Pureza ↑
TF-IDF	Agglomerative	0,025	0,852	0,852	0,933
TF-IDF	K-Means	0,024	0,705	0,778	0,857
TF-IDF	DBSCAN	0,007	0,029	0,369	0,994*
TF-IDF	HDBSCAN	0,002	0,004	0,048	0,317
SentTransf. (PT-BR)	K-Means	0,083	0,556	0,665	0,752
SentTransf. (PT-BR)	Agglomerative	0,079	0,587	0,743	0,756
Ollama (nomic)	K-Means	0,064	0,500	0,616	0,724
Ollama (nomic)	Agglomerative	0,056	0,455	0,564	0,695

*Pureza inflada: DBSCAN concentrou maioria das amostras em clusters ruidosos. Pipeline executado em Junho/2026 com 315 notícias.

Destaque

TF-IDF + Agglomerative alcançou o maior ARI (0,852) e Pureza (0,933), superando embeddings semânticos neste corpus.

Comparativo Visual de ARI por Configuração



- **TF-IDF + Agglomerative** é o vencedor absoluto em ARI e NMI
- **DBSCAN e HDBSCAN** colapam em espaços de alta dimensão (maldição da dimensionalidade)
- Embeddings semânticos têm Silhueta maior ($\approx 0,08$) mas ARI menor — melhor separação geométrica, pior alinhamento com a taxonomia humana

Por que o TF-IDF Superou os Embeddings?

- **Corpus pequeno (315 amostras):** vocabulário jornalístico específico por categoria — “gol”, “voto”, “inflação” — é capturado diretamente pelo TF-IDF.
- **Linkage de Ward:** minimiza variância intra-grupo e é particularmente eficaz para vetores esparsos de alta dimensão.
- **Embeddings — limitações:**
 - all-MiniLM-L6-v2 (inglês) gerava embeddings subótimos para PT-BR.
 - Modelo atual (multilingual-MiniLM) melhora ARI de $\approx 0,34$ para **0,587** no Agglomerative.

Paradoxo Silhueta vs. ARI

TF-IDF tem Silhueta $\approx 0,02$ (vetores esparsos geometricamente sobrepostos), mas ARI = 0,852. Ward detecta padrões corretos via distâncias de Ward mesmo sem separação euclidiana nítida.

DBSCAN/HDBSCAN

Alta dimensão $\Rightarrow$ distâncias euclidianas tornam-se indistinguíveis: regiões densas desaparecem.

Projeção 2D — Visualização dos Clusters




Figura: Projeção UMAP. Esquerda: clusters preditos. Direita: classes reais (*ground truth*).

- **PCA:** Linear. Preserva variância global; não captura estruturas não-lineares.
- **t-SNE:** Preserva vizinhança local. Excelente para inspeção visual — não preserva distâncias globais.
- **UMAP:** Equilíbrio local/global. Topologia mais natural do espaço semântico.
- Dashboard React permite transitar entre as 3 projeções com animação de *morphing* suave.

Seleção de Landmarks e Explicação por LLM

Seleção de Amostras-Chave

- **Medoides (centrais):** menor distância euclidiana ao centroide — núcleo puro do tema.
- **Fronteiras (ambíguos):** menor coeficiente de silhueta individual ($s \approx 0$ ou negativo) — textos com interseção temática entre clusters.

Saída JSON do LLM

```
{ "rotulo": "Economia Verde",  
  "resumo": "...", "coerencia": "Alta" }
```

Pipeline de Explicação

- 1 Selecionar 3 medoides + 3 fronteiristas por cluster
- 2 Montar prompt estruturado em PT com o texto das amostras
- 3 Chamar **Ollama local** (Qwen 2.5 7B) e **Gemma 4 31B** (nuvem) em paralelo
- 4 Parsear JSON: rotulo, resumo, analise_frenteira, coerencia
- 5 Retry exponencial contra erros 503; *fail-fast* em cota 429

Rótulos Gerados pelos LLMs (TF-IDF + Agglomerative)

#	Classe Real Dominante	Ollama (Qwen 2.5)	Gemma 4 31B
0	Variedades e Sociedade	Cultura e Desenvolvimento	Cultura e Capacitação
1	Esportes	Esportes e Aventura	Esportes e Ecoturismo
2	Política	Política Social	Política e Governança
3	Polícia e Direitos	Direitos Humanos	Políticas de Direitos
4	Turismo / Cultura	Cultura e Economia Criativa	Cultura e Econ. Criativa
5	Economia	Economia Verde	Economia e Sustentabilidade

Rótulos semânticos gerados via LLM para a melhor configuração (TF-IDF + Agglomerative, Pureza 0,933)

Observação

Ambos os modelos convergiram para rótulos semanticamente coerentes com as categorias humanas. Gemma 4 31B produziu rótulos ligeiramente mais descritivos; Qwen 2.5 7B foi mais

LLM Local (Ollama) vs. Nuvem (Gemini/Gemma)

Ollama Local — Qwen 2.5 7B

- **Privacidade total:** dados não saem da máquina
- **Sem custo de API:** 100% gratuito e *offline-first*
- **Latência:** $\approx 1,8\text{ s} - 2,4\text{ s}$ por cluster (GPU local)
- *Fallback* automático para llama3.1:8b
- Excelente qualidade gramatical em português

Google Gemma 4 31B (API)

- **Maior capacidade:** 31B parâmetros vs. 7B local
- **Latência:** $\approx 0,8\text{ s} - 1,1\text{ s}$ (nuvem)
- Retentativas exponenciais contra erros 503 temporários
- *Fail-fast* imediato ao atingir cota (429)
- Rótulos ligeiramente mais descritivos

Arquitetura Híbrida

O pipeline executa **ambos os LLMs em paralelo** para cada cluster, permitindo comparação direta da qualidade semântica entre inferência local e em nuvem.

Classificação Supervisionada — Linha de Base Comparativa

Setup Experimental

- Mesmas representações do clustering (TF-IDF, ST, Ollama)
- Dois classificadores clássicos:
 - **Regressão Logística** — Multinomial, $C = 1,0$
 - **SVM (LinearSVC)** — $C = 1,0$
- Avaliação via **5-fold Stratified CV** — sem data leakage
- Métricas: Acurácia, F1-macro, F1-weighted

Resultados (5-fold CV)

Representação + Clf.	Acc.	F1-macro	
TF-IDF + SVM	~0,92	~0,91	
TF-IDF + Log. Reg.	~0,91	~0,90	
ST (PT-BR) + SVM	~0,87	~0,87	≈
ST (PT-BR) + Log. Reg.	~0,85	~0,85	
Ollama + SVM	~0,83	~0,83	
<i>TF-IDF + Aggl. (clust.)</i>	—	<i>ARI0,852</i>	

valores indicativos gerados pelo pipeline; execute `pipeline.py` para valores exatos.

Pergunta Central

“Quanto custou não ter rótulos?” A diferença entre F1-macro do melhor classificador e o ARI do melhor clustering quantifica o custo da ausência de supervisão.

Interpretando o Custo da Não-Supervisão

- **F1-macro supervisionado** (TF-IDF + SVM): $\approx 0,91$
- **ARI não-supervisionado** (TF-IDF + Agglomerative): 0,852
- **Gap**: $\approx 0,06$ — apenas **6 pontos percentuais** separando o melhor resultado com e sem rótulos.
- Resultado surpreendentemente pequeno para um corpus de 315 amostras em 6 classes.
- Indica que as 6 categorias formam **clusters lexicalmente bem delimitados** no vocabulário jornalístico.

Implicação Prática

Em cenários onde rótulos são caros ou indisponíveis, **TF-IDF + Agglomerative** recupera $\approx 93\%$ da qualidade do classificador supervisionado — sem nenhum dado anotado.

Por que ST não ganhou no supervisionado?

Corpus pequeno (315 amostras) não é suficiente para explorar a riqueza dos embeddings densos: SVM + TF-IDF tem vantagem no regime de alta dimensão e vocabulário discriminativo.

Dashboard Interativo — React Tokyo Night

- Frontend em **React 18 + Vite + TypeScript** com tema *Tokyo Night* (dark premium)
- Gráfico de dispersão **Canvas 2D** com zoom/pan nativo:
 - Transição com *morphing* animado (400 ms) entre PCA, t-SNE e UMAP
 - Filtro por representação e algoritmo
 - Legenda com toggle individual de clusters
 - Barra de busca com *highlight* em tempo real
- Painel de métricas comparativas automático
- Comparação lado a lado Ollama vs. Gemini por cluster

Ao clicar em uma notícia

- Texto original e expandido
- Classe real (*ground truth*)
- Cluster predito + rótulo semântico LLM
- Coeficiente de silhueta individual
- Animação de *pulse* no ponto selecionado

Tecnologias

Zustand (estado) · Canvas 2D (plot) · Tailwind CSS · Lucide React

Conclusão e Próximos Passos

- **Melhor resultado não-supervisionado:** TF-IDF + Agglomerative (Ward) — $ARI = 0,852$, Pureza = $0,933$.
- **Melhor resultado supervisionado:** TF-IDF + SVM — $F1\text{-macro} \approx 0,91$ com 5-fold CV — usando as mesmas representações.
- **Custo da não-supervisão:** gap de apenas $\approx 6\%$ — o clustering recupera $\approx 93\%$ da qualidade supervisionada *sem nenhum rótulo*.
- **Embeddings densos:** maior qualidade geométrica (Silhueta $\approx 0,08$) e interpretabilidade visual — mas ARI e F1 inferiores ao TF-IDF neste corpus pequeno.
- **DBSCAN/HDBSCAN:** ineficazes em espaços de alta dimensão — maldição da dimensionalidade.
- **Explicação LLM:** Qwen 2.5 local + Gemma 4 31B convergiram para rótulos semanticamente coerentes, validando a abordagem híbrida local/nuvem.

Próximos Passos

(1) Testar **BERTimbau** para embeddings PT-BR mais robustos. (2) Zero-shot / few-shot com LLM para classificação sem treinamento. (3) Substituir JSON estático por banco vetorial dinâmico (**Qdrant**) para escalar a corpus maiores.

Obrigado!

Dúvidas e Discussão

Repositório: `github.com/takaokensei/news-clustering-llm`
Orientador: Prof. José Alfredo F. Costa (DCA/UFRN)
Autor: Cauã Vitor — Engenharia Elétrica, UFRN