

Agrupamento de Notícias com Análise por LLM

Comparação entre Representações Freqüenciais, Embeddings Densos e
Explicação Semântica Automatizada com Modelos de Linguagem

Cauã Vitor

Orientador: Prof. José Alfredo F. Costa

Universidade Federal do Rio Grande do Norte (UFRN)
Departamento de Engenharia de Computação e Automação (DCA)

Junho de 2026

Roteiro da Apresentação

- 1 Motivação e Objetivo
- 2 Representações Vetoriais
- 3 Algoritmos de Clustering
- 4 Métricas de Avaliação
- 5 Resultados Experimentais
- 6 Explicação Semântica via LLM
- 7 Visualizador Interativo

- **Problema:** Agrupar automaticamente notícias em categorias temáticas *sem supervisão humana* — tarefa clássica e desafiadora em PLN.
- **Dataset:** 315 notícias em português distribuídas em **6 classes temáticas** rotuladas:
 - Política, Economia, Esportes
 - Cultura, Saúde, Tecnologia/Meio Ambiente
- **Questão de Pesquisa:** Qual representação vetorial e qual algoritmo produz grupos mais coerentes com a semântica humana?

Abordagem do Experimento

- 1 Vetorização: TF-IDF vs Embeddings Densos
- 2 Clustering: 4 algoritmos distintos
- 3 Projeção 2D: PCA, t-SNE, UMAP
- 4 Explicação Semântica via LLM Local + Nuvem

TF-IDF (Frequencial)

- Abordagem clássica: sacola de palavras (bag-of-words)
- Apenas frequência léxica — ignora contexto semântico
- Vocabulário: até **1000 termos** após remoção de stopwords PT
- Equação:

$$\text{TF-IDF}(t, d, D) = \text{tf}(t, d) \cdot \log\left(\frac{|D|}{1 + |\{d : t \in d\}|}\right)$$

Embeddings Semânticos Densos

- Modelos neurais pré-treinados que mapeiam textos em espaços contínuos
- Capturam sinônimos, contexto e relações implícitas
- **SentenceTransformers:**
all-MiniLM-L6-v2 — 384 dimensões
- **Ollama (local):**
nomic-embed-text — 768 dimensões

Algoritmos de Agrupamento Testados

K-Means

Agrupamento particional que minimiza a inércia intra-cluster. Assume agrupamentos convexos e de tamanho similar.

DBSCAN

Baseado em densidade. Identifica *outliers* como ruído (-1). Sensível ao parâmetro ϵ e dimensionalidade do espaço.

Agglomerative (Ward)

Hierárquico ascendente (*bottom-up*).
Mescla pares de clusters pelo critério de Ward (menor variância dentro do grupo).

HDBSCAN

Versão hierárquica do DBSCAN. Suporta densidades variáveis sem parâmetro ϵ fixo. Robusto a outliers.

Não Supervisionadas (sem ground truth)

- **Coeficiente de Silhueta:**

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \in [-1, +1]$$

onde $a(i)$ = distância intra-cluster, $b(i)$ = distância ao cluster vizinho mais próximo.

- **Davies-Bouldin:** Menor $\Rightarrow$ clusters mais compactos e separados.

Supervisionadas (vs. Classes Reais)

- **ARI (Adjusted Rand Index):**

Concordância corrigida pelo acaso entre partição predita e *ground truth*.
Ideal = 1.0.

- **NMI (Normalized Mutual Info):**

Baseada em teoria da informação.

- **Pureza:** Fração das amostras na classe majoritária de cada cluster.

Resultados Quantitativos Completos

Representação	Algoritmo	<i>K</i>	Silhueta	ARI	NMI	Pureza
TF-IDF	Agglomerative	6	0.025	0.852	0.852	0.933
TF-IDF	K-Means	6	0.024	0.705	0.778	0.857
TF-IDF	DBSCAN	29	0.007	0.029	0.369	0.994
TF-IDF	HDBSCAN	2	0.002	0.004	0.048	0.318
SentTransf.	K-Means	6	0.064	0.422	0.499	0.689
SentTransf.	Agglomerative	6	0.046	0.338	0.423	0.625
Ollama Nomic	K-Means	6	0.064	0.500	0.616	0.724
Ollama Nomic	Agglomerative	6	0.056	0.455	0.565	0.695

Métricas experimentais reais (pipeline executado com 315 notícias em Junho/2026).

Por que o TF-IDF Superou os Embeddings?

- **Dataset Pequeno (315 amostras):** TF-IDF em corpus pequeno captura bem os termos discriminativos das 6 classes — já que cada classe usa vocabulário específico e consistente.
- **Linguagem Estruturada:** Notícias jornalísticas em português têm vocabulário de domínio bem delimitado (p.ex.: “gol”, “voto”, “inflação”).
- **Embeddings — Limitações no Contexto:**
 - all-MiniLM-L6-v2 foi treinado majoritariamente em inglês.
 - nomic-embed-text multimodal: não captura a distinção de classes tão bem em corpus pequeno.

Interpretação

Silhueta do TF-IDF é baixa (≈ 0.02) indicando que os vetores esparsos são geometricamente superpostos — mas o clustering hierárquico ainda detecta padrões corretos via distâncias de Ward.

DBSCAN/HDBSCAN

Inadequados para espaços de alta dimensão — problema da *maldição da dimensionalidade*: distâncias tornam-se indistinguíveis.

Projeção 2D — Visualização dos Clusters




Figura: Projeção UMAP (SentenceTransformers + K-Means).
Esquerda: grupos preditos. Direita: classes reais.

- **PCA:** Projeção linear. Preserva variância global, mas não separa clusters curvos.
- **t-SNE:** Preserva estrutura local. Ideal para inspeção visual — mas não preserva distâncias globais.
- **UMAP:** Compromisso entre local e global. Revela agrupamentos com topologia mais natural.
- Dashboard interativo React permite inspecionar cada ponto individualmente.

Seleção de Amostras Chave

- **Medoides (centrais):** Documentos com menor distância euclidiana ao centroide. Núcleo puro do cluster.
- **Fronteira (ambíguos):** Documentos com menor coeficiente de silhueta individual (próximos a 0 ou negativos). Indicam interseção temática.

Pipeline de Explicação

- 1 Selecionar 3 medoides + 3 fronteiristas por cluster
- 2 Montar prompt estruturado (1 × por cluster)
- 3 Chamar LLM: **Ollama local** (Qwen 2.5 7B) + **Gemma 4 31B** (nuvem)
- 4 Obter JSON: `rotulo`, `resumo`, `analise_frenteira`, `coerencia`

Rótulos Gerados pelos LLMs para os Clusters

Cluster	Classe Real Dominante	Ollama (Qwen 2.5)	Gemma 4 31B
0	Tecnologia/Inovação	Desenvolvimento e Inovação	Desenvolvimento e Capacitação
1	Esportes	Esportes e Aventura	Esportes e Ecoturismo
2	Política	Política Social e Democrática	Política e Governança Social
3	Direitos Humanos	Direitos Humanos	Políticas de Direitos Humanos
4	Cultura	Cultura e Economia Criativa	Cultura e Economia Criativa
5	Economia/Meio Ambiente	Economia Verde	Economia Verde e Sustentabilidade

Tabela: Rótulos semânticos gerados automaticamente via LLM (SentenceTransformers + K-Means).

Observação

Ambos os modelos convergiram para rótulos semanticamente consistentes com as categorias humanas. Gemma 4 31B produziu rótulos ligeiramente mais descritivos; Qwen 2.5 7B foi mais conciso e direto.

LLM Local (Ollama) vs Nuvem (Gemini/Gemma)

Ollama Local — Qwen 2.5 7B

- **Privacidade total:** Dados não saem da máquina
- **Sem custo de API:** 100% gratuito e offline-first
- **Latência:** $\approx$ 1.8s a 2.4s por cluster (GPU local)
- **Fallback automático** para llama3.1:8b em caso de erro
- Excelente qualidade gramatical em português

Google Gemma 4 31B (API)

- **Maior capacidade:** 31B parâmetros vs 7B local
- **Latência:** $\approx$ 0.8s a 1.1s (nuvem)
- Retentativas exponenciais contra erros 503 temporários
- *Fail-fast* imediato ao atingir cota (429)
- Rótulos ligeiramente mais descritivos e detalhados

Arquitetura Híbrida

O pipeline executa **em paralelo** ambos os LLMs para cada cluster, permitindo comparação direta da qualidade semântica entre modelos local e em nuvem.

Dashboard Interativo — React Tokyo Night

- Frontend em **React + Vite** com tema *Tokyo Night* (modo escuro premium)
- Gráfico de dispersão interativo com **Recharts**:
 - Alternância em tempo real entre: PCA, t-SNE, UMAP
 - Filtro por Representação (TF-IDF, ST, Ollama) e Algoritmo
 - Clique em legenda para **ativar/desativar clusters**
 - Clique em ponto: painel lateral com texto original, classe real, cluster e rótulo LLM
- Tabela de métricas comparativa em tempo real
- Painel de explicação LLM por cluster (Ollama vs Gemini)

Funcionalidades do Ponto

Ao clicar em uma notícia no gráfico:

- Texto original e expandido
- Classe real (*ground truth*)
- Cluster predito
- Rótulo semântico gerado pelo LLM
- Coeficiente de silhueta individual

Conclusão

- **Resultado Principal:** TF-IDF + Agglomerative (Ward) obteve o maior ARI (0.852) neste corpus pequeno de 315 notícias jornalísticas em PT-BR.
- **Embeddings Densos:** Maior qualidade geométrica (Silhueta ≈ 0.06) e interpretabilidade visual via projeções UMAP/t-SNE — mas ARI inferior ao TF-IDF no corpus testado.
- **DBSCAN/HDBSCAN:** Desempenho limitado em espaços de alta dimensão — maldição da dimensionalidade.
- **Explicação LLM:** Ambos os modelos (Qwen 2.5 local + Gemma 4 31B) produziram rótulos semanticamente coerentes — validando a abordagem híbrida local/nuvem.
- **Pipeline Reprodutível:** Código aberto, configuração via `.env`, visualizador interativo para análise exploratória.

Próximos Passos

Substituir cache JSON por banco vetorial dinâmico (**Elasticsearch** / **Qdrant** via Docker) para escalabilidade a centenas de milhares de notícias.

Obrigado!

Dúvidas e Discussão

Repositório: `github.com/takaokensei/news-clustering-llm`
Orientador: Prof. José Alfredo F. Costa (DCA/UFRN)
Autor: Cauã Vitor — Engenharia Elétrica, UFRN